

Universidad Autónoma de Tamaulipas

Facultad de Ingeniería y Ciencias

Cómputo Evolutivo

Localización óptima de centros de acopio agrícola en Tamaulipas

Alumno: Gustavo Echeverría Salinas

Docente: Dr. Alan Díaz Manríquez

Asignatura: Cómputo Evolutivo

Fecha: 26 de agosto del 2026

Resumen

La localización de centros de acopio constituye un problema relevante para la planeación de infraestructura logística agrícola, debido a que la ubicación de las instalaciones influye directamente en las distancias requeridas para concentrar la producción distribuida territorialmente. En este trabajo se aborda la localización de centros de acopio de sorgo grano en los 43 municipios del estado de Tamaulipas, México, mediante técnicas de Computación Evolutiva. Cada municipio se consideró simultáneamente como punto de demanda y sitio candidato para la instalación de un centro de acopio. La producción agrícola municipal correspondiente al año 2024 se utilizó como ponderador de la demanda, mientras que la separación entre municipios se representó mediante distancias Haversine entre sus cabeceras municipales.

El problema se estudió mediante tres formulaciones. En primer lugar, se implementó un algoritmo genético monoobjetivo para minimizar la distancia promedio ponderada por producción, considerando un número fijo de centros $p \in \{3, 5, 7, 10\}$. Su desempeño se comparó con tres líneas base: selección aleatoria, selección de municipios con mayor producción y una heurística voraz. Posteriormente, se utilizó NSGA-II para incorporar como segundo objetivo la minimización de la distancia máxima de atención. Finalmente, se planteó una formulación de tres objetivos en la que también se minimizó el número de centros instalados, permitiendo configuraciones de entre 3 y 10 instalaciones.

El algoritmo genético obtuvo distancias promedio ponderadas de 32.56, 16.62, 9.64 y 3.72 km para $p = 3$, $p = 5$, $p = 7$ y $p = 10$, respectivamente. Frente a la selección aleatoria, estas soluciones representaron mejoras de 72.91 %, 78.81 %, 86.97 % y 92.36 %. La prueba pareada de Wilcoxon mostró diferencias estadísticamente significativas entre ambos métodos. Sin embargo, la heurística voraz alcanzó el mismo desempeño que el algoritmo genético para $p = 5$, $p = 7$ y $p = 10$, evidenciando la importancia de utilizar líneas base competitivas.

Los resultados multiobjetivo mostraron un conflicto entre la eficiencia promedio y la cobertura territorial, ya que las soluciones que minimizan la distancia promedio ponderada no necesariamente reducen la distancia del municipio peor atendido. Asimismo, la incorporación del número de instalaciones permitió identificar rendimientos decrecientes al incrementar la infraestructura. En particular, una configuración de nueve centros alcanzó la misma mejor distancia máxima observada con diez instalaciones, aproximadamente 64.31 km. Los resultados muestran que la Computación Evolutiva permite generar diferentes alternativas de localización y analizar explícitamente los compromisos existentes entre eficiencia logística, cobertura territorial y cantidad de infraestructura.

Palabras clave: Computación Evolutiva, algoritmo genético, NSGA-II, optimización multiobjetivo, localización de instalaciones, centros de acopio, logística agrícola.

1. Introducción

La localización de instalaciones constituye una decisión estratégica en el diseño de cadenas de suministro, ya que determina la proximidad entre la infraestructura y los puntos de demanda y, por tanto, influye en las distancias de transporte, la cobertura territorial y el desempeño logístico [3]. Este problema resulta especialmente relevante en cadenas agrícolas, donde la producción se encuentra distribuida geográficamente y debe concentrarse para facilitar su almacenamiento, procesamiento y distribución [4, 5].

En este contexto, los centros de acopio permiten concentrar la producción procedente de diferentes zonas. Sin embargo, su localización debe considerar tanto la distribución espacial como los volúmenes producidos. Minimizar únicamente una distancia promedio sin ponderación asignaría la misma importancia a municipios con producciones muy distintas; por ello, en este trabajo las distancias se ponderan mediante la producción municipal. A su vez, optimizar solamente la eficiencia promedio puede dejar municipios periféricos considerablemente alejados, lo que introduce un conflicto entre eficiencia logística y cobertura territorial.

El número de instalaciones constituye otra dimensión de la decisión. Una mayor cantidad de centros tiende a reducir las distancias de atención, pero implica mayor infraestructura. Aunque los costos económicos no se modelan explícitamente, el número de centros se utiliza como una aproximación simplificada de esta dimensión. El problema puede entonces analizarse mediante objetivos relacionados con distancia promedio ponderada, distancia máxima y cantidad de instalaciones.

La búsqueda exhaustiva puede resultar costosa debido al crecimiento combinatorio del espacio de soluciones. Para n ubicaciones candidatas y p centros, existen

$$N_{\text{soluciones}} = \binom{n}{p} = \frac{n!}{p!(n-p)!}. \quad (1)$$

Con 43 municipios y $p = 10$ existen 1 917 334 783 combinaciones posibles. Esto motiva el empleo de métodos de búsqueda como los algoritmos genéticos, cuyos fundamentos fueron establecidos por Holland [6].

Para incorporar objetivos conflictivos se utilizó NSGA-II, propuesto por Deb *et al.* [1], que aproxima un conjunto de soluciones no dominadas mediante ordenamiento por dominancia y preservación de diversidad. En lugar de producir una única respuesta, este enfoque permite analizar compromisos entre diferentes criterios de decisión.

El caso de estudio considera los 43 municipios de Tamaulipas como puntos de demanda y sitios candidatos para centros de acopio de sorgo grano. La producción municipal de 2024 se empleó como ponderador y las distancias entre cabeceras se calcularon mediante Haversine. Primero se resolvió un problema monoobjetivo para $p \in \{3, 5, 7, 10\}$ mediante un algoritmo genético y se comparó con selección aleatoria, selección por producción y una heurística voraz. Posteriormente, NSGA-II permitió incorporar la distancia máxima de atención y, finalmente, el número de centros como tercer objetivo.

El objetivo del trabajo es analizar la capacidad de técnicas de computación evolutiva para generar alternativas de localización y estudiar los compromisos entre eficiencia, cobertura territorial e infraestructura. El procedimiento integra datos agrícolas y geográficos con optimización monoobjetivo y multiobjetivo, proporcionando escenarios de apoyo a la planeación en lugar de una ubicación definitiva de infraestructura.

2. Descripción del caso de estudio

El caso de estudio se desarrolló para el estado de Tamaulipas, México, considerando sus 43 municipios como unidades territoriales para el planteamiento del problema de localización. El análisis se enfocó en la producción de sorgo grano correspondiente al año 2024, utilizando la producción registrada en cada municipio como una medida de la demanda que debe ser atendida por la red de centros de acopio.

El sorgo presenta una distribución territorial heterogénea dentro del estado, por lo que los municipios no contribuyen de manera uniforme al problema. Algunos concentran una proporción considerable de la producción, mientras que otros presentan volúmenes menores. Esta característica resulta relevante para el modelo de optimización, ya que una solución basada exclusivamente en distancias geográficas otorgaría la misma importancia a todos los municipios independientemente de su participación en la producción total.

Por esta razón, la producción municipal se incorporó como factor de ponderación dentro de la función objetivo. De esta forma, las distancias asociadas con municipios de mayor producción tienen una influencia proporcionalmente mayor sobre el valor de la solución. Este planteamiento permite representar de manera más adecuada el objetivo logístico de acercar la infraestructura de acopio a las principales zonas productoras sin excluir del análisis a los municipios con menor producción.

Cada uno de los 43 municipios se consideró simultáneamente como un punto de demanda y como una ubicación candidata para instalar un centro de acopio. Por lo tanto, el algoritmo no genera nuevas coordenadas geográficas para las instalaciones, sino que selecciona un subconjunto de las cabeceras municipales existentes. Esta decisión permite formular el problema como una selección discreta de ubicaciones.

Sea el conjunto de municipios

$$M = \{1, 2, \dots, n\}, \quad (2)$$

donde $n = 43$. Para cada municipio $i \in M$ se dispone de su producción de sorgo w_i y de su posición geográfica, representada mediante latitud ϕ_i y longitud λ_i .

A partir de estas coordenadas se construyó una matriz de distancias entre las cabeceras municipales. La distancia entre dos municipios i y j se calculó mediante la fórmula de Haversine, la cual permite estimar la distancia sobre la superficie terrestre a partir de sus coordenadas geográficas:

$$a = \sin^2\left(\frac{\Delta\phi}{2}\right) + \cos(\phi_i)\cos(\phi_j)\sin^2\left(\frac{\Delta\lambda}{2}\right), \quad (3)$$

$$c = 2 \arctan 2\left(\sqrt{a}, \sqrt{1-a}\right), \quad (4)$$

$$d_{ij} = R c, \quad (5)$$

donde $\Delta\phi = \phi_j - \phi_i$, $\Delta\lambda = \lambda_j - \lambda_i$, R representa el radio medio de la Tierra y d_{ij} corresponde a la distancia estimada, expresada en kilómetros, entre las cabeceras de los municipios i y j .

El empleo de esta distancia permite transformar las coordenadas geográficas en una matriz simétrica de separación entre los municipios. En consecuencia,

$$d_{ij} = d_{ji}, \quad (6)$$

y la distancia de un municipio consigo mismo es

$$d_{ii} = 0. \quad (7)$$

La Fig. 1 presenta la distribución de las distancias obtenidas entre las cabeceras municipales consideradas. Se observa una dispersión considerable de las separaciones territoriales, con una mayor concentración de pares de municipios en distancias intermedias y algunos casos que superan los 500 km. Esta distribución evidencia la extensión territorial del problema y muestra que una cantidad reducida de centros puede producir diferencias importantes en la cobertura de los municipios más alejados.




Figura 1: Distribución de las distancias entre las cabeceras municipales consideradas en el caso de estudio.

Para facilitar posteriormente la representación gráfica de las soluciones, las coordenadas geográficas también se transformaron a un sistema cartesiano local expresado en kilómetros. Esta transformación se utilizó únicamente con fines de visualización de la distribución espacial de los municipios y de las ubicaciones seleccionadas como centros de acopio. La evaluación de las soluciones se realizó utilizando la matriz de distancias calculada a partir de las coordenadas geográficas.

Una solución del problema queda determinada por el subconjunto de municipios seleccionados como centros. Para una cantidad fija de instalaciones p , se define

$$S \subseteq M, \quad |S| = p, \quad (8)$$

donde S representa el conjunto de centros seleccionados. Una vez definida una solución, cada municipio se asigna al centro seleccionado que presenta la menor distancia:

$$j_i^* = \arg \min_{j \in S} d_{ij}. \quad (9)$$

Por lo tanto, la distancia de atención correspondiente al municipio i se define como

$$d_i(S) = \min_{j \in S} d_{ij}. \quad (10)$$

Este procedimiento genera implícitamente zonas de atención alrededor de los centros seleccionados y permite evaluar una misma configuración desde diferentes perspectivas. En las formulaciones desarrolladas posteriormente se utiliza esta información para calcular la distancia promedio ponderada por producción y la distancia máxima de atención.

El planteamiento inicial considera cuatro escenarios con un número fijo de centros, $p \in \{3, 5, 7, 10\}$, para estudiar cómo cambia la eficiencia logística conforme aumenta la infraestructura disponible. Posteriormente, en la formulación de tres objetivos, esta restricción se flexibiliza y el número de centros se incorpora como una variable del propio problema de optimización, considerando configuraciones comprendidas entre 3 y 10 instalaciones.

3. Formulación matemática del problema

El problema de localización se formuló considerando los 43 municipios de Tamaulipas simultáneamente como puntos de demanda y ubicaciones candidatas para la instalación de centros de acopio. La selección de las instalaciones se representó mediante variables binarias, mientras que la calidad de cada configuración se evaluó a partir de las distancias entre las cabeceras municipales y la producción de sorgo correspondiente a cada municipio.

Sea $n = 43$ el número total de municipios y sea

$$x = (x_1, x_2, \dots, x_n) \quad (11)$$

el vector binario que representa una solución. Cada variable de decisión se define como

$$x_j = \begin{cases} 1, & \text{si el municipio } j \text{ es seleccionado como centro de acopio,} \\ 0, & \text{en otro caso.} \end{cases} \quad (12)$$

Por lo tanto, el número total de centros presentes en una solución puede determinarse mediante

$$p(x) = \sum_{j=1}^n x_j. \quad (13)$$

Sea además P_i la producción anual de sorgo grano correspondiente al municipio i , expresada en toneladas, y d_{ij} la distancia Haversine entre las cabeceras municipales i y j , expresada en kilómetros.

Para una solución x , cada municipio se asigna al centro seleccionado más cercano. En consecuencia, la distancia mínima de atención correspondiente al municipio i se define como

$$d_i^{\min}(x) = \min_{j: x_j=1} d_{ij}. \quad (14)$$

A partir de esta distancia se plantearon tres criterios de optimización: la distancia promedio ponderada por producción, la distancia máxima de atención y el número de centros seleccionados.

3.1. Formulación monoobjetivo

La primera formulación considera un número fijo de centros de acopio y busca minimizar la distancia promedio ponderada por la producción agrícola. Para ello se define la función objetivo

$$f_1(x) = \frac{\sum_{i=1}^n P_i d_i^{\min}(x)}{\sum_{i=1}^n P_i}. \quad (15)$$

La ponderación mediante P_i permite incorporar la importancia relativa de cada municipio de acuerdo con su volumen de producción. De esta forma, una reducción en la distancia correspondiente a un municipio con elevada producción tiene una mayor influencia sobre el valor de f_1 que una reducción equivalente en un municipio con menor producción.

El problema monoobjetivo se expresa entonces como

$$\min_x f_1(x), \quad (16)$$

sujeto a la restricción de cardinalidad

$$\sum_{j=1}^n x_j = p, \quad (17)$$

con $p \in \{3, 5, 7, 10\}$. De esta manera, se resolvieron cuatro instancias independientes del problema, correspondientes a la instalación de 3, 5, 7 y 10 centros de acopio.

La función f_1 puede interpretarse como la distancia que, en promedio, debe cubrir una unidad de producción para alcanzar el centro de acopio más cercano. Por esta razón, su minimización favorece configuraciones próximas a las regiones con mayor concentración de producción.

Sin embargo, este criterio no garantiza por sí mismo una distribución territorial uniforme. Un municipio con una producción relativamente baja puede permanecer alejado de cualquier centro sin producir un incremento considerable en f_1 . Esta característica motivó la incorporación de un segundo criterio relacionado con la cobertura territorial.

3.2. Formulación multiobjetivo con dos objetivos

Para analizar simultáneamente la eficiencia promedio y la cobertura territorial, se incorporó como segundo objetivo la distancia correspondiente al municipio peor atendido.

La función se define como

$$f_2(x) = \max_i d_i^{\min}(x). \quad (18)$$

Mientras que f_1 representa el comportamiento promedio de la solución considerando la producción, f_2 mide la mayor distancia existente entre cualquier municipio y el centro de acopio que le fue asignado.

El problema multiobjetivo queda definido como

$$\min_x (f_1(x), f_2(x)), \quad (19)$$

manteniendo la restricción

$$\sum_{j=1}^n x_j = p, \quad (20)$$

para $p \in \{3, 5, 7, 10\}$. Los dos objetivos presentan un comportamiento potencialmente conflictivo. Una configuración puede proporcionar un valor reducido de f_1 al localizar centros próximos a los municipios con mayor producción, pero mantener un valor elevado de f_2 si algún municipio periférico queda alejado de las instalaciones.

Por el contrario, reducir f_2 puede requerir instalar centros en ubicaciones que mejoren la cobertura de municipios alejados aunque estas regiones representen una proporción menor de la producción total. Esto puede ocasionar un incremento en f_1 .

Por esta razón, la formulación no busca combinar ambos criterios mediante una suma ponderada. En su lugar, se utiliza optimización multiobjetivo para obtener un conjunto de soluciones no dominadas que permita observar directamente el compromiso existente entre ambos criterios.

Una solución $x^{(a)}$ domina a otra solución $x^{(b)}$ si

$$f_k(x^{(a)}) \leq f_k(x^{(b)}) \quad \forall k \in \{1, 2\}, \quad (21)$$

y existe al menos un objetivo para el cual

$$f_k(x^{(a)}) < f_k(x^{(b)}). \quad (22)$$

Las soluciones que no son dominadas por ninguna otra alternativa forman una aproximación al Frente de Pareto. Este conjunto permite seleccionar diferentes configuraciones dependiendo de la importancia otorgada a la eficiencia promedio o a la cobertura territorial.

3.3. Formulación multiobjetivo con tres objetivos

En las formulaciones anteriores, el número de centros p se establece previamente. Sin embargo, desde una perspectiva de planeación, la cantidad de infraestructura también constituye una variable relevante.

Para incorporar este aspecto se definió un tercer objetivo correspondiente al número de centros seleccionados:

$$f_3(x) = \sum_{j=1}^n x_j. \quad (23)$$

La formulación completa queda entonces definida como

$$\min_x (f_1(x), f_2(x), f_3(x)), \quad (24)$$

sujeta a

$$3 \leq \sum_{j=1}^n x_j \leq 10. \quad (25)$$

A diferencia de los experimentos anteriores, en esta formulación el algoritmo puede explorar soluciones con diferentes cantidades de centros. El objetivo f_3 introduce una medida simplificada de la cantidad de infraestructura requerida, de manera que una solución con menor número de instalaciones resulta preferible respecto a este criterio.

Los tres objetivos permiten estudiar diferentes dimensiones del problema. El primer objetivo,

$$f_1(x), \quad (26)$$

representa la eficiencia logística promedio ponderada por producción; el segundo,

$$f_2(x), \quad (27)$$

representa la cobertura territorial mediante la distancia del municipio peor atendido; mientras que

$$f_3(x) \quad (28)$$

representa la cantidad de infraestructura seleccionada.

En términos generales, aumentar el número de centros tiende a reducir f_1 y f_2 , debido a que existen más ubicaciones disponibles para atender los municipios. Sin embargo, este comportamiento implica un incremento de f_3 . La formulación de tres objetivos permite, por lo tanto, estudiar los rendimientos obtenidos al incorporar infraestructura adicional y determinar en qué punto las mejoras en distancia comienzan a ser relativamente menores.

3.4. Líneas base

Antes de aplicar los algoritmos evolutivos se implementaron tres métodos de referencia. El propósito de estas estrategias fue establecer diferentes niveles de desempeño contra los cuales comparar posteriormente las soluciones obtenidas mediante el algoritmo genético.

Las tres líneas base fueron evaluadas mediante la misma función objetivo f_1 definida en la Ecuación 15. Por lo tanto, para cualquier configuración de centros se determinó inicialmente el centro seleccionado más cercano a cada municipio y posteriormente se calculó la distancia promedio ponderada por producción.

Las estrategias utilizadas fueron: selección aleatoria, selección de los municipios con mayor producción y construcción voraz.

3.4.1. Selección aleatoria

La primera línea base consistió en seleccionar aleatoriamente p municipios de los 43 sitios candidatos, sin permitir repeticiones. Esta estrategia no utiliza información relacionada con la producción agrícola ni con las distancias entre municipios durante la construcción de la solución, por lo que proporciona una referencia básica del desempeño que puede obtenerse mediante configuraciones generadas al azar.

Para cada valor de p se realizaron 30 corridas independientes. Con el propósito de garantizar la reproducibilidad de los experimentos, se utilizaron las semillas enteras comprendidas entre 0 y 29. Por lo tanto, para cada escenario se generó el conjunto

$$R_p = \{x_p^{(0)}, x_p^{(1)}, \dots, x_p^{(29)}\}, \quad (29)$$

donde $x_p^{(s)}$ representa la solución aleatoria generada utilizando la semilla s para una configuración de p centros.

Cada solución contiene exactamente p municipios seleccionados y se evaluó mediante f_1 . Debido al carácter estocástico de este procedimiento, no resulta suficiente reportar únicamente la mejor solución obtenida. Para cada valor de p se calcularon cinco estadísticos descriptivos: mejor valor, peor valor, media, mediana y desviación estándar.

La media se calculó mediante

$$\bar{f}_p = \frac{1}{30} \sum_{r=1}^{30} f_1(x_p^{(r)}), \quad (30)$$

mientras que la desviación estándar permitió cuantificar la variabilidad existente entre las configuraciones generadas aleatoriamente.

Esta línea base permitió establecer una referencia estocástica para determinar cuánto mejora el desempeño cuando la selección de las ubicaciones se realiza utilizando información del problema o mediante un proceso de optimización.

3.4.2. Heurística basada en producción

La segunda línea base utilizó directamente la producción agrícola como criterio de selección. Para cada valor de p , los 43 municipios se ordenaron de manera descendente de acuerdo con su producción anual de sorgo grano y se seleccionaron como centros de acopio los primeros p municipios de este ordenamiento.

Si los municipios ordenados por producción se representan mediante

$$P_{(1)} \geq P_{(2)} \geq \dots \geq P_{(43)}, \quad (31)$$

el conjunto de centros seleccionado mediante esta estrategia queda definido por

$$S_p^{\text{prod}} = \{(1), (2), \dots, (p)\}. \quad (32)$$

A diferencia de la selección aleatoria, esta estrategia es determinista y, por lo tanto, genera una única configuración para cada valor de p .

La lógica de esta heurística consiste en instalar infraestructura directamente en los municipios que concentran los mayores volúmenes de producción. Desde el punto de vista de la función f_1 , esta decisión resulta intuitiva debido a que las distancias se encuentran ponderadas precisamente por la producción municipal.

Sin embargo, la estrategia no considera explícitamente la separación espacial entre los municipios seleccionados. Dos municipios con elevada producción pueden encontrarse geográficamente próximos, por lo que seleccionar ambos no necesariamente proporciona la mejor cobertura del territorio. De esta manera, la heurística permite evaluar si utilizar únicamente información sobre la magnitud de la demanda resulta suficiente para obtener configuraciones competitivas.

3.4.3. Heurística voraz

La tercera línea base se implementó mediante una estrategia voraz de construcción incremental. A diferencia de la heurística anterior, este procedimiento considera directamente el efecto que produce cada municipio candidato sobre la función objetivo.

El procedimiento comienza con un conjunto vacío de centros:

$$S_0 = . \quad (33)$$

En cada iteración t , se consideran todos los municipios que todavía no forman parte del conjunto de centros. Para cada candidato $j \notin S_t$, se construye temporalmente la solución

$$S_t^{(j)} = S_t \cup \{j\}, \quad (34)$$

y se calcula el valor de la función objetivo correspondiente.

El siguiente centro se selecciona mediante

$$j^* = \arg \min_{j \notin S_t} f_1(S_t \cup \{j\}). \quad (35)$$

Posteriormente, el conjunto de centros se actualiza como

$$S_{t+1} = S_t \cup \{j^*\}. \quad (36)$$

El proceso se repite hasta satisfacer

$$|S_t| = p. \quad (37)$$

De esta manera, cada nuevo centro corresponde al municipio que produce la mayor reducción disponible de la distancia promedio ponderada en esa etapa de construcción.

La estrategia es determinista y genera una única solución para cada valor de p . Su principal diferencia respecto a la heurística basada en producción consiste en que la decisión de incorporar un municipio depende tanto de su relación con la demanda como de la configuración de centros previamente seleccionada.

Esto permite considerar indirectamente la distribución espacial de los municipios. Por ejemplo, una ubicación con una producción individual menor puede ser seleccionada si su incorporación reduce considerablemente las distancias de varios municipios productores.

Debido a que esta heurística utiliza directamente la función objetivo para construir las soluciones, representa una línea base más competitiva que la selección aleatoria y la selección basada exclusivamente en producción. Por esta razón, su comparación con el algoritmo genético resulta particularmente relevante para determinar si la exploración evolutiva del espacio de búsqueda proporciona una mejora adicional.

Las tres estrategias proporcionan referencias progresivamente más informadas. La selección aleatoria no utiliza características específicas del problema durante la construcción de las soluciones. La heurística por producción incorpora información sobre la magnitud de la demanda, pero no considera explícitamente la distribución espacial. Finalmente, la estrategia voraz utiliza directamente la función objetivo y, por lo tanto, considera simultáneamente la producción y las distancias al evaluar cada nueva ubicación.

Cuadro 1: Características de las líneas base utilizadas.

Método	Producción	Distancias	Estocástico
Aleatorio	No	No	Sí
Producción	Sí	No	No
Voraz	Sí	Sí	No

3.5. Algoritmo genético monoobjetivo

La formulación monoobjetivo se resolvió mediante un algoritmo genético (GA) implementado en Python utilizando el framework PYMOO. Esta biblioteca proporciona herramientas para la implementación de algoritmos de optimización monoobjetivo y multiobjetivo, así como diferentes operadores evolutivos y mecanismos para el tratamiento de restricciones [2].

Los algoritmos genéticos trabajan con una población de soluciones candidatas que evoluciona a lo largo de diferentes generaciones mediante operadores inspirados en mecanismos evolutivos. En cada generación, los individuos son evaluados de acuerdo con una función objetivo y posteriormente se aplican operadores de selección, cruzamiento y mutación para generar nuevas soluciones.

En el problema estudiado, cada individuo representa una configuración completa de centros de acopio. Debido a que existen 43 municipios candidatos, se utilizó una representación binaria de longitud 43:

$$x = (x_1, x_2, \dots, x_{43}), \quad (38)$$

donde cada posición indica si el municipio correspondiente forma parte de la solución. Para los experimentos monoobjetivo, cada individuo debe contener exactamente p posiciones activas.

El algoritmo se ejecutó independientemente para $p \in \{3, 5, 7, 10\}$, permitiendo analizar el efecto de incrementar progresivamente la cantidad de infraestructura disponible.

3.5.1. Inicialización de la población

La población inicial estuvo formada por 100 individuos. Cada solución se generó de manera que contuviera exactamente p centros seleccionados, garantizando desde la inicialización el cumplimiento de la restricción de cardinalidad.

Para cada individuo se seleccionaron p posiciones diferentes dentro del vector de 43 variables y se asignó el valor uno a dichas posiciones. Las variables restantes se mantuvieron en cero. De esta manera,

$$\sum_{j=1}^{43} x_j = p \quad (39)$$

se cumple para todos los individuos de la población inicial.

El empleo de soluciones inicialmente factibles evita evaluar configuraciones que no representan alguno de los escenarios considerados y permite concentrar el proceso de búsqueda en combinaciones válidas de municipios.

3.5.2. Evaluación de los individuos

Cada individuo se evaluó mediante la distancia promedio ponderada por producción f_1 , definida previamente en la Ecuación 15.

Para cada solución se identificaron inicialmente las posiciones activas del vector binario, correspondientes a los municipios seleccionados como centros. Posteriormente, para cada uno de los 43 municipios se determinó la distancia al centro seleccionado más cercano utilizando la matriz de distancias.

El valor de aptitud resultante representa la distancia promedio ponderada que debe cubrir la producción para alcanzar el centro de acopio más cercano. Debido a que el problema es de minimización, los individuos con menores valores de f_1 representan configuraciones de mayor calidad.

La evaluación mediante la misma función utilizada para las líneas base permitió realizar posteriormente una comparación directa entre las diferentes estrategias.

3.5.3. Operador de cruzamiento

Para generar nuevas soluciones se utilizó un operador de cruzamiento de dos puntos (*Two-Point Crossover*). Este procedimiento selecciona dos posiciones del cromosoma y utiliza el segmento comprendido entre ellas para intercambiar información genética entre dos individuos progenitores.

Sean dos individuos

$$x^{(A)} = (x_1^{(A)}, \dots, x_{43}^{(A)}) \quad (40)$$

y

$$x^{(B)} = (x_1^{(B)}, \dots, x_{43}^{(B)}). \quad (41)$$

Al seleccionar dos puntos de corte c_1 y c_2 , con $c_1 < c_2$, los segmentos comprendidos entre estas posiciones pueden intercambiarse para producir nuevos individuos.

El operador se aplicó con una probabilidad de cruzamiento

$$p_c = 0,90. \quad (42)$$

La utilización de una probabilidad elevada favorece la recombinación de diferentes subconjuntos de municipios presentes en la población y permite generar nuevas configuraciones a partir de características de soluciones previamente evaluadas.

3.5.4. Operador de mutación

Después del cruzamiento se aplicó mutación binaria mediante el operador *Bit-Flip Mutation*. Este operador modifica el estado de determinadas posiciones del cromosoma:

$$0 \rightarrow 1 \quad \text{o} \quad 1 \rightarrow 0. \quad (43)$$

La probabilidad de mutación por variable se estableció como

$$p_m = \frac{1}{n}, \quad (44)$$

donde $n = 43$. Por lo tanto,

$$p_m = \frac{1}{43} \approx 0,02326. \quad (45)$$

Esta configuración produce, en promedio, una modificación del orden de una variable por individuo cuando se considera el cromosoma completo. La mutación permite introducir nuevas ubicaciones dentro de las soluciones y contribuye a mantener diversidad durante el proceso evolutivo.

3.5.5. Reparación de la restricción de cardinalidad

Aunque la población inicial se generó utilizando únicamente soluciones factibles, los operadores de cruzamiento y mutación pueden producir individuos cuyo número de posiciones activas sea diferente de p . Por esta razón, se implementó un operador de reparación después de las operaciones evolutivas.

Para cada individuo se calculó

$$q = \sum_{j=1}^{43} x_j, \quad (46)$$

donde q representa el número de centros presentes después de aplicar los operadores genéticos. Cuando

$$q > p, \quad (47)$$

se seleccionaron aleatoriamente $q - p$ posiciones activas y se modificaron de uno a cero. En cambio, cuando

$$q < p, \quad (48)$$

se seleccionaron aleatoriamente $p - q$ posiciones inactivas y se modificaron de cero a uno. Después del proceso de reparación se garantiza nuevamente

$$\sum_{j=1}^{43} x_j = p. \quad (49)$$

Este mecanismo permite utilizar operadores binarios convencionales sin perder la factibilidad de las soluciones respecto al número de centros requerido.

3.5.6. Configuración experimental

La Tabla 2 resume los principales parámetros utilizados para el algoritmo genético. La misma configuración se mantuvo para los cuatro valores de p con el propósito de realizar una comparación homogénea.

Cada configuración se ejecutó durante 200 generaciones con una población de 100 individuos. Debido a la naturaleza estocástica del algoritmo, se realizaron 30 corridas independientes para cada valor de p , utilizando las semillas enteras comprendidas entre 0 y 29.

Cuadro 2: Configuración experimental del algoritmo genético.

Parámetro	Configuración
Framework	PYMOO
Número de variables	43
Representación	Binaria
Población	100 individuos
Generaciones	200
Cruzamiento	Dos puntos
Probabilidad de cruzamiento	0.90
Mutación	Bit-flip
Probabilidad de mutación	1/43
Reparación	Cardinalidad exacta
Valores de p	3, 5, 7 y 10
Corridas por escenario	30
Semillas	0–29

La utilización de las mismas semillas que en la línea base aleatoria permitió construir posteriormente comparaciones pareadas entre ambos métodos. Para cada configuración se registraron el mejor valor, la media, la mediana, la desviación estándar y el peor valor obtenido en las 30 ejecuciones.

3.5.7. Flujo del proceso evolutivo

De manera general, el procedimiento comienza generando una población de soluciones factibles y evaluando cada individuo mediante f_1 . A partir de esta población se aplican los mecanismos evolutivos definidos por el algoritmo, seguidos de los operadores de cruzamiento y mutación. Las soluciones resultantes son reparadas cuando no satisfacen la cantidad requerida de centros y posteriormente vuelven a evaluarse.

Este ciclo se repite durante 200 generaciones. Al finalizar cada ejecución se conserva la mejor solución encontrada y su correspondiente valor de distancia promedio ponderada. El procedimiento completo se repite 30 veces para cada valor de p , lo que permite analizar tanto la calidad como la estabilidad del método.

3.6. Optimización multiobjetivo mediante NSGA-II

Las formulaciones multiobjetivo se resolvieron mediante el algoritmo *Non-dominated Sorting Genetic Algorithm II* (NSGA-II), propuesto por Deb et al. [1]. Este algoritmo fue diseñado para resolver problemas con múltiples objetivos potencialmente conflictivos mediante la evolución simultánea de una población de soluciones y la identificación progresiva de alternativas no dominadas.

A diferencia de la formulación monoobjetivo, en la que cada individuo puede ordenarse directamente de acuerdo con el valor de f_1 , en un problema multiobjetivo no necesariamente existe una única solución superior en todos los criterios. Una configuración puede presentar una menor

distancia promedio ponderada, mientras que otra puede proporcionar una mejor cobertura territorial. Por esta razón, NSGA-II utiliza el concepto de dominancia de Pareto para establecer la preferencia entre soluciones.

El algoritmo organiza la población mediante un procedimiento de ordenamiento por no dominancia. Las soluciones que no son dominadas por ningún otro individuo se incorporan al primer frente; posteriormente se eliminan temporalmente y se repite el procedimiento para identificar los siguientes niveles de dominancia. De esta manera, las soluciones pertenecientes a frentes inferiores tienen prioridad durante el proceso evolutivo.

Además del nivel de dominancia, NSGA-II utiliza la denominada *crowding distance* para favorecer la diversidad dentro de cada frente. Esta medida estima la separación de una solución respecto a sus vecinas en el espacio de objetivos. Cuando dos individuos pertenecen al mismo frente, se favorecen aquellos localizados en regiones menos pobladas. Este mecanismo contribuye a obtener soluciones distribuidas a lo largo del Frente de Pareto, en lugar de concentrar la búsqueda únicamente en una región del espacio objetivo [1].

En este trabajo se utilizó la implementación de NSGA-II disponible en PYMOO [2], manteniendo una representación binaria consistente con la empleada en el algoritmo genético monoobjetivo.

3.6.1. Optimización con dos objetivos

La primera extensión multiobjetivo consideró simultáneamente la distancia promedio ponderada por producción, f_1 , y la distancia máxima de atención, f_2 . En este experimento se mantuvo fijo el número de centros, por lo que se resolvieron nuevamente cuatro escenarios independientes:

$$p \in \{3, 5, 7, 10\}. \quad (50)$$

Cada individuo estuvo representado mediante un vector binario de 43 variables con exactamente p posiciones activas. Su evaluación produjo ahora un vector de dos objetivos:

$$F(x) = [f_1(x), f_2(x)]. \quad (51)$$

Ambos objetivos fueron minimizados simultáneamente.

Se utilizó una población de 100 individuos durante 200 generaciones. Los operadores evolutivos se mantuvieron consistentes con la formulación monoobjetivo: cruzamiento de dos puntos con probabilidad

$$p_c = 0,90, \quad (52)$$

y mutación *bit-flip* con probabilidad

$$p_m = \frac{1}{43}. \quad (53)$$

Después de aplicar los operadores evolutivos se utilizó nuevamente el mecanismo de reparación de cardinalidad para garantizar que todos los individuos conservaran exactamente p centros.

Al finalizar la evolución se conservaron las soluciones no dominadas obtenidas para cada escenario. Estas soluciones constituyen una aproximación al Frente de Pareto entre f_1 y f_2 y permiten observar cómo la mejora de la eficiencia promedio puede implicar un deterioro de la cobertura territorial, y viceversa.

3.6.2. Selección de soluciones representativas

Debido a que el resultado de una optimización multiobjetivo corresponde a un conjunto de soluciones no dominadas, se identificaron tres configuraciones representativas dentro de cada Frente de Pareto.

La primera corresponde a la solución con menor distancia promedio ponderada:

$$x_{f_1} = \arg \min_{x \in \mathcal{P}} f_1(x), \quad (54)$$

donde $\mathcal{P}$ representa el conjunto de soluciones no dominadas.

La segunda corresponde a la configuración con menor distancia máxima de atención:

$$x_{f_2} = \arg \min_{x \in \mathcal{P}} f_2(x). \quad (55)$$

Estas dos soluciones representan los extremos del compromiso analizado. Sin embargo, también se buscó identificar una alternativa intermedia que proporcionara un equilibrio entre ambos criterios.

Para evitar que la diferencia de escalas entre los objetivos afectara esta selección, los valores de cada objetivo se normalizaron dentro del Frente de Pareto:

$$\hat{f}_k(x) = \frac{f_k(x) - f_k^{\min}}{f_k^{\max} - f_k^{\min}}, \quad k \in \{1, 2\}. \quad (56)$$

Después de la normalización, el punto ideal corresponde a

$$z^* = (0, 0). \quad (57)$$

La distancia de cada solución respecto al punto ideal se calculó mediante

$$d_{\text{ideal}}(x) = \sqrt{\hat{f}_1(x)^2 + \hat{f}_2(x)^2}. \quad (58)$$

Finalmente, la solución de compromiso se definió como

$$x_{\text{comp}} = \arg \min_{x \in \mathcal{P}} d_{\text{ideal}}(x). \quad (59)$$

Este criterio no implica que la solución seleccionada sea universalmente preferible, sino que proporciona una alternativa representativa situada relativamente próxima al mejor valor normalizado de ambos objetivos.

3.6.3. Optimización con tres objetivos

Como extensión del problema multiobjetivo anterior, se incorporó un tercer objetivo para considerar explícitamente el número de centros de acopio instalados. A diferencia de los experimentos anteriores, en esta formulación el valor de p no se mantuvo fijo, permitiendo que NSGA-II determinara el número de centros como parte del proceso de optimización.

Se conservaron como primeros dos objetivos la distancia promedio ponderada por producción, f_1 , y la distancia máxima de atención, f_2 . El tercer objetivo se definió como el número total de centros seleccionados:

$$f_3(x) = \sum_{j=1}^{43} x_j. \quad (60)$$

Por lo tanto, cada individuo se evaluó mediante

$$F(x) = [f_1(x), f_2(x), f_3(x)]. \quad (61)$$

Los tres objetivos fueron minimizados simultáneamente.

Para evitar soluciones sin utilidad práctica o configuraciones excesivamente densas, se restringió la cantidad de instalaciones al intervalo

$$3 \leq f_3(x) \leq 10. \quad (62)$$

La población inicial se modificó para generar soluciones con una cantidad aleatoria de centros comprendida dentro de este intervalo. Asimismo, el operador de reparación utilizado después del cruzamiento y la mutación se adaptó a esta nueva restricción.

Cuando un individuo contenía menos de tres centros, se activaron posiciones adicionales hasta alcanzar el límite inferior. En cambio, cuando contenía más de diez centros, se eliminaron posiciones activas hasta satisfacer el límite superior. Las soluciones que ya se encontraban dentro del intervalo permitido no requirieron modificación.

3.6.4. Configuración del experimento de tres objetivos

La incorporación del número de instalaciones como variable de decisión incrementa el espacio de búsqueda, debido a que el algoritmo ya no explora únicamente combinaciones de cardinalidad fija. Por esta razón, para la formulación de tres objetivos se incrementó el tamaño de la población y el número de generaciones.

La configuración utilizada se presenta en la Tabla 3.

Cuadro 3: Configuración de los experimentos multiobjetivo.

Parámetro	2 objetivos	3 objetivos
Algoritmo	NSGA-II	NSGA-II
Variables	43	43
Representación	Binaria	Binaria
Población	100	150
Generaciones	200	300
Cruzamiento	2 puntos	2 puntos
p_c	0.90	0.90
Mutación	Bit-flip	Bit-flip
p_m	1/43	1/43
Centros	p fijo	3–10
Reparación	$ x = p$	$3 \leq x \leq 10$

El incremento de 100 a 150 individuos y de 200 a 300 generaciones permitió proporcionar una mayor capacidad de exploración para la formulación de tres objetivos. Al finalizar la ejecución se

conservaron las soluciones no dominadas y se analizaron de acuerdo con el número de centros presentes en cada configuración.

3.6.5. Análisis de las soluciones de tres objetivos

El conjunto no dominado obtenido mediante la formulación de tres objetivos permite estudiar simultáneamente el comportamiento de f_1 , f_2 y f_3 . Para facilitar su interpretación, las soluciones se agruparon de acuerdo con el número de centros seleccionados.

Para cada valor observado de f_3 se analizaron el menor valor de f_1 , el menor valor de f_2 y la distribución de las soluciones no dominadas correspondientes. Este procedimiento permitió determinar cómo evolucionan los criterios de distancia conforme aumenta progresivamente la cantidad de infraestructura.

La comparación entre configuraciones consecutivas también permite identificar rendimientos decrecientes. Si el incremento de p produce una reducción pequeña o nula en alguno de los criterios de distancia, la instalación adicional proporciona un beneficio marginal reducido respecto a ese objetivo.

Este análisis no busca determinar un número único de centros como solución universal. En su lugar, permite identificar regiones de interés dentro del Frente de Pareto y proporcionar información para una decisión posterior en la que podrían incorporarse criterios económicos, operativos o de política pública.

4. Diseño experimental y análisis estadístico

El diseño experimental se estableció con el propósito de comparar las diferentes estrategias de localización bajo condiciones homogéneas y evaluar tanto la calidad como la estabilidad de las soluciones obtenidas. Los experimentos se realizaron utilizando los mismos datos de producción, la misma matriz de distancias y las funciones objetivo definidas previamente.

Para el problema monoobjetivo se analizaron cuatro escenarios correspondientes a $p \in \{3, 5, 7, 10\}$, donde p representa el número de centros de acopio seleccionados. Estos valores permiten observar progresivamente el efecto de incrementar la infraestructura disponible sobre la distancia promedio ponderada por producción.

La selección aleatoria y el algoritmo genético se ejecutaron 30 veces para cada valor de p . En ambos casos se utilizaron las semillas enteras comprendidas entre 0 y 29, con el propósito de garantizar la reproducibilidad de los experimentos y permitir una comparación pareada entre ambos métodos.

Por otra parte, las estrategias basadas en producción y voraz son deterministas. En consecuencia, para una misma entrada y un mismo valor de p generan siempre la misma configuración, por lo que únicamente fue necesario realizar una ejecución para cada escenario.

Los experimentos multiobjetivo se realizaron posteriormente utilizando NSGA-II. En la formulación de dos objetivos se mantuvieron los cuatro valores fijos de p , mientras que en la formulación de tres objetivos el número de instalaciones pasó a formar parte del propio proceso de optimización, permitiendo soluciones comprendidas entre 3 y 10 centros.

4.1. Estadísticos descriptivos

Debido al carácter estocástico del algoritmo genético y de la línea base aleatoria, su evaluación no se realizó únicamente a partir de la mejor ejecución. Para cada conjunto de 30 corridas se calcularon diferentes estadísticos descriptivos con el propósito de caracterizar tanto la calidad como la variabilidad de las soluciones obtenidas.

Para cada valor de p se registraron el mejor resultado, la media, la mediana, la desviación estándar y el peor resultado de la función objetivo f_1 .

La media de las $N = 30$ ejecuciones se calculó mediante

$$\bar{f} = \frac{1}{N} \sum_{r=1}^N f^{(r)}, \quad (63)$$

donde $f^{(r)}$ representa el valor de la función objetivo obtenido en la corrida r .

La desviación estándar se calculó como

$$s = \sqrt{\frac{\sum_{r=1}^N (f^{(r)} - \bar{f})^2}{N - 1}}. \quad (64)$$

La media permite comparar el desempeño general de los métodos, mientras que la desviación estándar proporciona información sobre la estabilidad de las soluciones obtenidas entre diferentes ejecuciones. La mediana se incluyó como una medida adicional de tendencia central menos sensible a posibles valores extremos.

4.2. Comparación entre métodos

La evaluación del algoritmo genético se realizó comparando sus resultados contra las tres líneas base descritas previamente. Para cada valor de p se consideró la media obtenida mediante selección aleatoria, el resultado de la heurística basada en producción, el resultado de la heurística voraz y el desempeño del algoritmo genético.

Esta comparación permite establecer diferentes niveles de referencia. La selección aleatoria representa una estrategia sin información específica del problema; la selección basada en producción incorpora información sobre la distribución de la demanda; mientras que la heurística voraz utiliza directamente la función objetivo durante la construcción de las soluciones.

La inclusión de estas tres referencias resulta relevante debido a que superar únicamente una estrategia aleatoria no es suficiente para demostrar que un algoritmo evolutivo proporciona soluciones competitivas. En particular, la comparación con la heurística voraz permite evaluar el desempeño del GA frente a un procedimiento determinista diseñado específicamente para reducir la función objetivo.

4.3. Mejora porcentual

Además de comparar directamente los valores de la función objetivo, se calculó la mejora porcentual del algoritmo genético respecto a la selección aleatoria.

Para cada valor de p , la mejora se determinó mediante

$$\text{Mejora}(\%) = \frac{\bar{f}_{\text{aleatorio}} - \bar{f}_{\text{GA}}}{\bar{f}_{\text{aleatorio}}} \times 100, \quad (65)$$

donde $\bar{f}_{\text{aleatorio}}$ corresponde a la media de las 30 soluciones generadas aleatoriamente y $\bar{f}_{\text{GA}}$ representa la media de las 30 ejecuciones del algoritmo genético.

Un valor positivo indica una reducción de la distancia promedio ponderada respecto a la selección aleatoria. Cuanto mayor sea el porcentaje, mayor es la reducción obtenida mediante el proceso de optimización.

4.4. Prueba estadística de Wilcoxon

Para determinar si las diferencias observadas entre el algoritmo genético y la selección aleatoria podían atribuirse únicamente a la variabilidad de las ejecuciones, se realizó una comparación estadística mediante la prueba no paramétrica de rangos con signo de Wilcoxon.

Esta prueba resulta apropiada para comparar dos muestras relacionadas sin requerir asumir normalidad en la distribución de las diferencias. Debido a que la selección aleatoria y el algoritmo genético utilizaron las mismas semillas de 0 a 29, los resultados pudieron organizarse como pares correspondientes a cada semilla.

Para cada valor de p se consideraron las hipótesis

$$H_0 : \text{no existe una mejora sistemática del GA respecto al método aleatorio}, \quad (66)$$

y

$$H_1 : \text{el GA produce valores menores de } f_1 \text{ que el método aleatorio}. \quad (67)$$

Se utilizó un nivel de significancia de

$$\alpha = 0,05. \quad (68)$$

Por lo tanto, cuando

$$p_{\text{valor}} < 0,05, \quad (69)$$

se rechazó la hipótesis nula y se consideró que existía evidencia estadística de una mejora favorable al algoritmo genético.

La prueba se aplicó independientemente para $p = 3$, $p = 5$, $p = 7$ y $p = 10$. Los resultados estadísticos se analizaron conjuntamente con la mejora porcentual, ya que la significancia estadística por sí sola no describe la magnitud práctica de la diferencia entre los métodos.

4.5. Reproducibilidad de los experimentos

La implementación se desarrolló en Python y se organizó de manera que los experimentos pudieran reproducirse utilizando los archivos de datos procesados y las semillas especificadas.

Los resultados numéricos de las diferentes etapas se almacenaron en archivos CSV, incluyendo las ejecuciones de las líneas base, los resultados individuales del algoritmo genético, los resúmenes

estadísticos, la comparación entre métodos, los resultados de la prueba de Wilcoxon y los conjuntos de soluciones no dominadas obtenidos mediante NSGA-II.

Las figuras generadas durante el análisis también se almacenaron de manera independiente, incluyendo las comparaciones entre métodos, los Frentes de Pareto, el análisis del efecto del número de centros y las representaciones espaciales de las configuraciones seleccionadas.

Esta organización permite separar los datos originales, los resultados procesados y las figuras generadas, facilitando la verificación de los experimentos y la reutilización de los resultados para el análisis posterior.

5. Resultados y discusión

En esta sección se presentan los resultados obtenidos mediante las diferentes estrategias de localización. El análisis comienza con las líneas base utilizadas como referencia y posteriormente se estudia el comportamiento del algoritmo genético monoobjetivo. Después se presenta la comparación estadística entre los métodos y, finalmente, se analizan las formulaciones multiobjetivo mediante los Frentes de Pareto obtenidos con NSGA-II.

Los resultados se expresan principalmente en kilómetros. En el problema monoobjetivo, un menor valor de f_1 representa una menor distancia promedio ponderada por la producción de sorgo. En las formulaciones multiobjetivo, además de este criterio se considera la distancia máxima de atención f_2 y, posteriormente, el número de centros f_3 .

5.1. Desempeño de las líneas base

La Tabla 4 presenta los resultados obtenidos mediante las tres líneas base para los diferentes valores de p . En el caso de la selección aleatoria se reporta la media de las 30 corridas, mientras que las estrategias basadas en producción y voraz corresponden a una única solución determinista.

Cuadro 4: Resultados de las líneas base para diferentes cantidades de centros.

p	Aleatorio	Producción	Voraz
3	120.1782	38.9035	38.0230
5	78.4490	31.9029	16.6217
7	73.9715	10.2969	9.6398
10	48.7267	3.7936	3.7218

Los resultados muestran una reducción general de la distancia promedio ponderada conforme aumenta el número de centros. Este comportamiento era esperado, debido a que una mayor cantidad de instalaciones incrementa la probabilidad de que cada municipio disponga de un centro próximo.

Sin embargo, existen diferencias considerables entre las estrategias. La selección aleatoria presentó los mayores valores de f_1 en todos los escenarios. Para $p = 3$, la distancia promedio ponderada fue de aproximadamente 120.18 km, mientras que para $p = 10$ disminuyó hasta 48.73

km. Aunque el incremento del número de centros mejora el desempeño incluso bajo una selección aleatoria, los valores permanecen considerablemente por encima de los obtenidos mediante estrategias que incorporan información del problema.

La heurística basada en producción produjo una mejora importante respecto a la selección aleatoria. Para $p = 3$ se obtuvo una distancia promedio ponderada de 38.90 km y para $p = 10$ el valor disminuyó hasta 3.79 km. Este comportamiento muestra que la producción constituye una variable relevante para determinar las ubicaciones de los centros, particularmente debido a que la función objetivo pondera explícitamente las distancias mediante esta variable.

No obstante, seleccionar únicamente los municipios con mayor producción no produjo las mejores configuraciones en todos los escenarios. Para $p = 5$, por ejemplo, la heurística basada en producción obtuvo un valor de 31.90 km, mientras que la estrategia voraz redujo el resultado hasta 16.62 km. La diferencia indica que la concentración de producción no es el único factor que determina una buena configuración: la distribución espacial de las instalaciones también desempeña un papel importante.

La heurística voraz presentó el mejor desempeño entre las líneas base. Los valores obtenidos fueron 38.02, 16.62, 9.64 y 3.72 km para $p = 3$, $p = 5$, $p = 7$ y $p = 10$, respectivamente. La construcción incremental permite considerar el efecto que produce cada nuevo centro sobre el conjunto completo de municipios, lo que favorece una distribución espacial más eficiente que la obtenida al ordenar únicamente por producción.

5.2. Resultados del algoritmo genético

La Tabla 5 presenta los estadísticos obtenidos en las 30 ejecuciones independientes del algoritmo genético para cada valor de p .

Cuadro 5: Resultados del algoritmo genético en 30 corridas independientes.

p	Mejor	Media	Mediana	Desv. est.	Peor
3	32.5614	32.5614	32.5614	0.0000	32.5614
5	16.6217	16.6217	16.6217	0.0000	16.6217
7	9.6398	9.6398	9.6398	0.0000	9.6398
10	3.7218	3.7218	3.7218	0.0000	3.7218

El algoritmo genético obtuvo valores de f_1 iguales a 32.56, 16.62, 9.64 y 3.72 km para $p = 3$, $p = 5$, $p = 7$ y $p = 10$, respectivamente. Al igual que en las líneas base, se observa una reducción considerable de la distancia promedio ponderada conforme aumenta el número de centros.

Un resultado particularmente relevante corresponde a la estabilidad observada entre las ejecuciones. Para los cuatro valores de p , el mejor valor, la media, la mediana y el peor resultado fueron iguales dentro de la precisión reportada, produciendo una desviación estándar de cero.

Este comportamiento indica que las 30 ejecuciones convergieron consistentemente al mismo valor de la función objetivo bajo la configuración experimental utilizada. Sin embargo, este resul-

tado no constituye una demostración formal de optimalidad global, debido a que no se realizó una enumeración exhaustiva del espacio completo de soluciones.

La consistencia observada sugiere que, para esta instancia y los valores de p estudiados, la combinación del tamaño de población, número de generaciones, operadores evolutivos y mecanismo de reparación proporcionó suficiente capacidad de búsqueda para alcanzar repetidamente configuraciones de igual calidad.

5.3. Comparación del algoritmo genético con las líneas base

La Tabla 6 presenta conjuntamente los resultados de las líneas base y del algoritmo genético.

Cuadro 6: Comparación de la distancia promedio ponderada entre los métodos evaluados.

p	Aleatorio	Producción	Voraz	GA
3	120.1782	38.9035	38.0230	32.5614
5	78.4490	31.9029	16.6217	16.6217
7	73.9715	10.2969	9.6398	9.6398
10	48.7267	3.7936	3.7218	3.7218

La comparación muestra que el algoritmo genético superó ampliamente a la selección aleatoria para todos los valores de p . Asimismo, obtuvo mejores resultados que la estrategia basada exclusivamente en producción en los cuatro escenarios considerados.

La diferencia entre el GA y la heurística voraz fue considerablemente menor. Para $p = 3$, el algoritmo genético alcanzó 32.56 km frente a 38.02 km obtenidos mediante la estrategia voraz, lo que representa una reducción adicional de aproximadamente 5.46 km.

Para $p = 5$, ambos métodos alcanzaron 16.62 km; para $p = 7$, 9.64 km; y para $p = 10$, 3.72 km. Por lo tanto, en estos tres escenarios no se observó una mejora numérica del algoritmo genético respecto a la heurística voraz.

Este resultado es importante para la evaluación del método evolutivo. Aunque el GA presenta un desempeño claramente superior frente a las estrategias aleatoria y basada en producción, la heurística voraz demuestra ser altamente competitiva para esta instancia. En consecuencia, los resultados no permiten afirmar que el algoritmo genético sea superior a todas las estrategias consideradas. En cambio, muestran que tanto la búsqueda evolutiva como una estrategia voraz diseñada específicamente para la función objetivo pueden alcanzar soluciones de elevada calidad.

La Fig. ?? permite observar gráficamente la diferencia de desempeño entre los métodos. La selección aleatoria presenta valores considerablemente superiores, particularmente cuando el número de centros es reducido. Conforme aumenta p , las diferencias absolutas disminuyen debido a que la disponibilidad de más instalaciones reduce las distancias incluso para estrategias simples.

La estrategia basada en producción presenta una mejora considerable respecto al método aleatorio, pero mantiene una diferencia visible frente al GA y la heurística voraz, especialmente para $p = 5$. Por otra parte, las curvas correspondientes al algoritmo genético y al método voraz prácticamente coinciden a partir de cinco centros, en concordancia con los valores numéricos reportados en la Tabla 6.

5.4. Análisis estadístico del desempeño

La comparación de los valores medios permite observar una ventaja considerable del algoritmo genético respecto a la selección aleatoria. Sin embargo, debido al carácter estocástico de ambos procedimientos, se realizó adicionalmente una prueba estadística pareada de Wilcoxon para determinar si las diferencias observadas se mantienen de manera consistente entre las ejecuciones.

Para cada valor de p se utilizaron las 30 corridas correspondientes a las semillas de 0 a 29. La Tabla 7 presenta el estadístico de Wilcoxon, el valor- p , las medias de ambos métodos y la mejora porcentual obtenida mediante el algoritmo genético.

Cuadro 7: Comparación estadística entre la selección aleatoria y el algoritmo genético.

p	W	Valor- p	Aleatorio	GA	Mejora (%)
3	465.0	$9,31 \times 10^{-10}$	120.1782	32.5614	72.91
5	465.0	$9,31 \times 10^{-10}$	78.4490	16.6217	78.81
7	465.0	$9,31 \times 10^{-10}$	73.9715	9.6398	86.97
10	465.0	$9,31 \times 10^{-10}$	48.7267	3.7218	92.36

Para los cuatro escenarios se obtuvo un valor- p de aproximadamente

$$9,31 \times 10^{-10}, \quad (70)$$

considerablemente inferior al nivel de significancia establecido de $\alpha = 0,05$. Por lo tanto, se rechaza la hipótesis nula en los cuatro casos y se encuentra evidencia estadística de una diferencia sistemática favorable al algoritmo genético respecto a la selección aleatoria.

La magnitud de la mejora también resulta relevante. Para $p = 3$, la distancia promedio ponderada disminuyó de 120.18 km en la selección aleatoria a 32.56 km mediante el algoritmo genético, correspondiente a una reducción de 72.91 %. Al utilizar cinco centros, la mejora aumentó hasta 78.81 %.

Para $p = 7$, el algoritmo genético redujo la distancia promedio ponderada de 73.97 a 9.64 km, alcanzando una mejora de 86.97 %. Finalmente, para $p = 10$, la media de la selección aleatoria fue de 48.73 km, mientras que el algoritmo genético obtuvo 3.72 km, correspondiente a la mayor reducción porcentual observada, con 92.36 %.

Estos resultados muestran que la diferencia entre ambos métodos no solamente es estadísticamente significativa, sino también considerable desde el punto de vista de la función objetivo. Asimismo, la mejora porcentual aumenta conforme se incrementa el número de centros considerados en los escenarios analizados.

No obstante, esta conclusión debe interpretarse específicamente respecto a la selección aleatoria. La prueba de Wilcoxon no se aplicó a las heurísticas de producción y voraz debido a que estas estrategias son deterministas y producen una única solución para cada valor de p . En particular, los resultados presentados previamente muestran que la heurística voraz alcanzó el mismo valor que el algoritmo genético en tres de los cuatro escenarios, por lo que la evidencia estadística frente a la selección aleatoria no debe interpretarse como evidencia de superioridad del GA frente a todas las estrategias consideradas.

5.5. Efecto del número de centros sobre la eficiencia

Los resultados monoobjetivo permiten analizar directamente el efecto de incrementar la cantidad de centros de acopio. Considerando las mejores soluciones obtenidas mediante el algoritmo genético, la distancia promedio ponderada disminuyó de 32.56 km con tres centros a 16.62 km con cinco centros. Posteriormente, disminuyó hasta 9.64 km con siete instalaciones y alcanzó 3.72 km cuando se utilizaron diez centros.

La reducción relativa entre configuraciones consecutivas puede calcularse mediante

$$R_{a \rightarrow b} = \frac{f_1(a) - f_1(b)}{f_1(a)} \times 100. \quad (71)$$

Al pasar de tres a cinco centros, la distancia promedio ponderada disminuyó aproximadamente 48.95 %. El incremento de cinco a siete centros produjo una reducción adicional cercana al 42.00 %, mientras que el cambio de siete a diez centros redujo f_1 aproximadamente 61.39 %.

Estos resultados confirman que incrementar la cantidad de infraestructura proporciona una mejora considerable en la eficiencia promedio. Sin embargo, el análisis monoobjetivo no permite determinar si estas configuraciones proporcionan también una cobertura territorial equilibrada.

En particular, una distancia promedio reducida puede ocultar la existencia de municipios considerablemente alejados de cualquier centro de acopio. Esta limitación constituye la principal motivación para analizar posteriormente la distancia máxima de atención mediante la formulación multiobjetivo.

5.6. Optimización multiobjetivo: eficiencia y cobertura territorial

La formulación monoobjetivo permitió encontrar configuraciones con valores reducidos de distancia promedio ponderada por producción. Sin embargo, este criterio no considera directamente la situación del municipio más alejado de la infraestructura seleccionada. Para analizar esta característica se resolvió el problema mediante NSGA-II considerando simultáneamente la minimización de f_1 , correspondiente a la distancia promedio ponderada, y f_2 , correspondiente a la distancia máxima de atención.

Para cada valor de p se obtuvo un conjunto de soluciones no dominadas que representa diferentes compromisos entre ambos criterios. La Tabla 8 resume el número de soluciones obtenidas y tres puntos representativos de cada Frente de Pareto: la solución con menor f_1 , la solución con menor f_2 y la solución de compromiso seleccionada mediante la distancia normalizada al punto ideal.

Cuadro 8: Resultados de la optimización multiobjetivo para diferentes cantidades de centros.

p	Soluciones	$f_1^{\min}$	f_2 en $f_1^{\min}$	f_1 en $f_2^{\min}$	$f_2^{\min}$	f_1 compromiso	f_2 compromiso
3	11	32.5614	218.7570	89.5045	138.0459	59.7711	166.3944
5	10	16.6217	218.7570	29.7023	106.0083	19.5093	159.1214
7	13	9.6398	218.7570	39.7127	81.4828	13.7626	106.0083
10	19	3.7218	197.3279	32.0021	59.6012	9.1996	91.8203

Los resultados evidencian un conflicto claro entre los dos objetivos. Las configuraciones que minimizan f_1 proporcionan una elevada eficiencia desde la perspectiva de la producción total, pero

pueden mantener distancias máximas considerablemente altas. Por el contrario, reducir f_2 requiere redistribuir los centros para proporcionar una cobertura territorial más uniforme, aun cuando esto incremente la distancia promedio ponderada.

5.6.1. Conflicto entre la eficiencia promedio y la cobertura territorial

El conflicto entre los objetivos puede observarse claramente al analizar sus valores extremos. Para $p = 3$, la solución que minimiza f_1 alcanza una distancia promedio ponderada de solamente 32.56 km. Sin embargo, en esa misma configuración el municipio peor atendido se encuentra a una distancia de 218.76 km del centro más cercano.

Cuando se prioriza f_2 , la distancia máxima disminuye hasta 138.05 km. Esta mejora en cobertura requiere, no obstante, incrementar f_1 hasta 89.50 km. Por lo tanto, reducir aproximadamente 80.71 km la distancia del municipio peor atendido implica aumentar considerablemente la distancia promedio ponderada.

Un comportamiento similar se presenta para $p = 5$. La mejor solución respecto a f_1 alcanza 16.62 km, pero mantiene un valor de f_2 de 218.76 km. Al priorizar la cobertura territorial, f_2 disminuye hasta 106.01 km, mientras que f_1 aumenta hasta 29.70 km.

Para $p = 7$, la configuración que minimiza f_1 obtiene 9.64 km, pero nuevamente presenta una distancia máxima de 218.76 km. En el extremo contrario del Frente de Pareto, f_2 puede reducirse hasta 81.48 km, aunque f_1 aumenta hasta 39.71 km.

Finalmente, con diez centros, el menor valor de f_1 es 3.72 km y su distancia máxima asociada es 197.33 km. Al priorizar f_2 , la distancia máxima disminuye hasta 59.60 km, mientras que f_1 aumenta hasta 32.00 km.

Estos resultados muestran que la reducción de la distancia promedio ponderada puede concentrar los centros alrededor de las regiones que representan una mayor proporción de la producción. Desde la perspectiva de f_1 , esta distribución resulta eficiente debido a que los municipios de baja producción tienen una influencia menor sobre el promedio ponderado. Sin embargo, algunos de estos municipios pueden quedar considerablemente alejados de cualquier instalación.


En contraste, la minimización de f_2 obliga a distribuir parte de la infraestructura hacia regiones territorialmente alejadas, incluso cuando su participación en la producción total sea menor. De esta manera, la cobertura territorial mejora a costa de una pérdida de eficiencia respecto a f_1 .

La Fig. 2 muestra los Frentes de Pareto obtenidos para los cuatro escenarios. Cada punto representa una configuración diferente de centros de acopio que no es dominada por otra solución del conjunto obtenido.


La pendiente negativa observable en los frentes confirma visualmente el conflicto entre los objetivos. Desplazarse hacia menores valores de f_1 generalmente implica aceptar mayores valores de f_2 , mientras que reducir la distancia máxima requiere sacrificar parcialmente la eficiencia promedio ponderada.

También se observa un desplazamiento general de los frentes hacia menores valores de distancia conforme aumenta p . Esto indica que disponer de una mayor cantidad de instalaciones amplía la capacidad del sistema para proporcionar simultáneamente una buena eficiencia promedio y una mejor cobertura territorial.


Sin embargo, incluso con diez centros permanece un compromiso entre ambos criterios. Por lo tanto, aumentar la infraestructura reduce el conflicto, pero no elimina la necesidad de establecer prioridades para seleccionar una configuración particular.




(a) $p = 3$.



(b) $p = 5$.



(c) $p = 7$.



(d) $p = 10$.

Figura 2: Frentes de Pareto obtenidos mediante NSGA-II para la minimización simultánea de la distancia promedio ponderada f_1 y la distancia máxima de atención f_2 .

5.6.2. Análisis de las soluciones de compromiso

Además de analizar los extremos de cada Frente de Pareto, se seleccionó una solución de compromiso mediante la distancia euclidiana normalizada al punto ideal. Estas configuraciones proporcionan una referencia intermedia cuando no se desea priorizar exclusivamente ninguno de los dos objetivos.

Para $p = 3$, la solución de compromiso presentó

$$f_1 = 59,77 \text{ km}, \quad f_2 = 166,39 \text{ km}. \quad (72)$$

Esta configuración incrementa la distancia promedio respecto al mínimo de 32.56 km, pero reduce la distancia máxima desde 218.76 hasta 166.39 km.

Para $p = 5$, la solución de compromiso alcanzó

$$f_1 = 19,51 \text{ km}, \quad f_2 = 159,12 \text{ km}. \quad (73)$$

En este caso, f_1 permanece relativamente próximo a su mínimo de 16.62 km, mientras que f_2 mejora respecto a los 218.76 km asociados con la solución que optimiza exclusivamente f_1 .

Con siete centros se obtuvo

$$f_1 = 13,76 \text{ km}, \quad f_2 = 106,01 \text{ km}, \quad (74)$$

mientras que para diez centros la solución de compromiso presentó

$$f_1 = 9,20 \text{ km}, \quad f_2 = 91,82 \text{ km}. \quad (75)$$

La evolución de estas soluciones muestra que aumentar la cantidad de centros permite mejorar simultáneamente ambos criterios. Sin embargo, las configuraciones de compromiso no deben interpretarse como soluciones óptimas únicas. Su selección depende del procedimiento de normalización y de considerar igual importancia para ambos objetivos. En una aplicación real, el responsable de la toma de decisiones podría seleccionar cualquier otra solución del Frente de Pareto dependiendo de las prioridades logísticas y territoriales.

Los resultados multiobjetivo también permiten reinterpretar el desempeño obtenido previamente mediante el algoritmo genético monoobjetivo. Los valores de 32.56, 16.62, 9.64 y 3.72 km encontrados al minimizar únicamente f_1 aparecen nuevamente como los extremos de eficiencia de los respectivos Frentes de Pareto.

Sin embargo, el análisis de f_2 revela información que no era visible en la formulación monoobjetivo. En particular, las soluciones de menor f_1 mantienen distancias máximas superiores a 197 km en todos los escenarios estudiados. Por lo tanto, una configuración excelente desde el punto de vista de la producción promedio no necesariamente proporciona una cobertura territorial adecuada.

Este resultado justifica la utilización de una formulación multiobjetivo para el problema de localización. En lugar de producir únicamente una configuración, NSGA-II permite generar un conjunto de alternativas que hacen explícito el costo asociado con mejorar uno de los criterios respecto al otro.

5.7. Optimización con tres objetivos

La última formulación incorporó el número de centros como tercer objetivo, permitiendo que NSGA-II explorara configuraciones con entre 3 y 10 instalaciones. De esta manera, el problema permitió analizar simultáneamente la distancia promedio ponderada f_1 , la distancia máxima de atención f_2 y la cantidad de centros f_3 .

La Tabla 9 resume las soluciones no dominadas agrupadas según el número de centros. Para cada valor de f_3 se presentan el número de soluciones obtenidas, los mejores valores observados de f_1 y f_2 , así como sus valores medios.

Cuadro 9: Resultados de la optimización con tres objetivos según el número de centros.

f_3	Soluciones	Mejor f_1	Mejor f_2	Media f_1	Media f_2
3	10	32.5614	138.0459	62.1301	171.4007
4	10	20.4873	125.2327	37.9853	155.8812
5	10	16.6217	106.0083	24.8690	148.3839
6	13	12.7804	95.2291	22.6398	132.9946
7	12	9.6398	81.4828	18.3723	128.3816
8	12	6.5049	80.6429	15.4543	116.8721
9	15	4.5419	64.3055	13.9184	107.3801
10	16	3.7218	64.3055	10.0065	104.6901

Los resultados muestran una mejora progresiva de f_1 conforme aumenta la infraestructura. La mejor distancia promedio ponderada disminuye de 32.56 km con tres centros hasta 3.72 km con diez. De manera similar, el mejor valor de f_2 disminuye de 138.05 km con tres centros hasta 64.31 km con nueve centros.

Sin embargo, ambos objetivos no presentan exactamente el mismo comportamiento al incrementar f_3 . Mientras que f_1 continúa mejorando hasta diez centros, el mejor valor de f_2 permanece en 64.31 km para nueve y diez instalaciones. Por lo tanto, la décima instalación proporciona una mejora adicional en eficiencia promedio, pero no reduce la mejor distancia máxima encontrada.

La Fig. 3 muestra la relación entre los tres criterios. Las soluciones con menor número de centros requieren aceptar mayores distancias de atención, mientras que el incremento de f_3 desplaza las soluciones hacia menores valores de f_1 y f_2 . Este comportamiento confirma el compromiso existente entre la cantidad de infraestructura y el desempeño logístico.

La Fig. 4 permite observar con mayor claridad el beneficio asociado con incrementar la infraestructura. La reducción de f_1 es continua en el intervalo estudiado, aunque las mejoras absolutas tienden a disminuir conforme aumenta el número de centros. Para f_2 , el comportamiento presenta una característica adicional: el mejor valor disminuye hasta nueve instalaciones, pero permanece en 64.31 km al incorporar un décimo centro.

Este resultado permite identificar un rendimiento marginal diferente dependiendo del criterio considerado. Si la prioridad fuera exclusivamente reducir la distancia máxima de atención, la solución de nueve centros resulta particularmente relevante, ya que la décima instalación no produjo una mejora adicional en el mejor f_2 encontrado. Sin embargo, si también se considera f_1 , diez centros continúan ofreciendo una ventaja, al reducir este objetivo de 4.54 a 3.72 km.






Figura 3: Soluciones no dominadas obtenidas mediante NSGA-II considerando simultáneamente f_1 , f_2 y f_3 .



(a) Efecto sobre f_1 .



(b) Efecto sobre f_2 .

Figura 4: Efecto del número de centros sobre los objetivos de distancia.

Por lo tanto, los resultados no permiten establecer un número de centros universalmente óptimo sin incorporar preferencias adicionales. En cambio, muestran que la formulación multiobjetivo permite identificar el beneficio marginal asociado con cada incremento de infraestructura y proporcionar diferentes alternativas para la toma de decisiones.

5.8. Análisis espacial de las soluciones

Además de evaluar numéricamente las configuraciones obtenidas, se representó espacialmente la localización de los centros seleccionados para analizar cómo cambia su distribución conforme aumenta la infraestructura disponible. La Fig. 5 presenta las soluciones correspondientes a $p = 3, 5, 7$ y 10 .

Los mapas muestran que, con una cantidad reducida de instalaciones, la selección tiende a concentrarse en ubicaciones estratégicas respecto a las principales zonas productoras. Conforme aumenta p , se incorporan nuevos centros que permiten reducir las distancias de atención y ampliar progresivamente la cobertura territorial.

Este comportamiento coincide con los resultados cuantitativos. La incorporación de centros adicionales reduce considerablemente f_1 , mientras que la formulación multiobjetivo muestra que una distribución territorial más amplia también permite disminuir f_2 . Por lo tanto, el incremento de infraestructura no solamente modifica el valor de las funciones objetivo, sino también la distribución espacial de la red de atención.


Debe señalarse que las ubicaciones representan cabeceras municipales y que las distancias utilizadas corresponden a distancias geográficas calculadas mediante Haversine. En consecuencia, los mapas deben interpretarse como una aproximación para el análisis de localización y no como el diseño definitivo de una red logística basada en distancias carreteras.

6. Conclusiones


En este trabajo se abordó la localización de centros de acopio de sorgo grano en Tamaulipas mediante técnicas de Computación Evolutiva, considerando la producción de los 43 municipios y su distribución geográfica. El problema se analizó mediante formulaciones monoobjetivo y multiobjetivo, permitiendo estudiar no solamente la eficiencia promedio de las configuraciones, sino también su cobertura territorial y la cantidad de infraestructura requerida.

En la formulación monoobjetivo, el algoritmo genético obtuvo distancias promedio ponderadas de 32.56, 16.62, 9.64 y 3.72 km para $p = 3, 5, 7$ y 10 , respectivamente. Las 30 ejecuciones convergieron al mismo valor para cada escenario y la comparación mediante la prueba de Wilcoxon mostró diferencias estadísticamente significativas respecto a la selección aleatoria. Sin embargo, la heurística voraz alcanzó resultados iguales al GA para $p = 5, 7$ y 10 , demostrando que una estrategia determinista relativamente sencilla puede ser altamente competitiva cuando incorpora directamente información de la función objetivo.


La optimización mediante NSGA-II permitió ampliar el análisis al considerar simultáneamente la distancia promedio ponderada f_1 y la distancia máxima de atención f_2 . Los Frentes de Pareto mostraron un conflicto entre ambos criterios: concentrar los centros cerca de las regiones con mayor producción favorece f_1 , pero puede dejar municipios considerablemente alejados de la




(a) $p = 3$.



(b) $p = 5$.



(c) $p = 7$.



(d) $p = 10$.

Figura 5: Distribución espacial de las soluciones obtenidas para diferentes cantidades de centros de acopio.

infraestructura. Por el contrario, mejorar la cobertura territorial requiere redistribuir los centros y aceptar un incremento en la distancia promedio ponderada.

Al incorporar el número de centros como tercer objetivo, se observó que aumentar la infraestructura mejora en términos generales los criterios de distancia, aunque con beneficios marginales diferentes. Particularmente, nueve centros permitieron alcanzar un mejor f_2 de 64.31 km, valor que no se redujo al utilizar diez instalaciones. No obstante, f_1 continuó mejorando de 4.54 a 3.72 km. Este resultado evidencia que la cantidad apropiada de centros depende de las prioridades consideradas y que no existe una única configuración que pueda considerarse superior bajo todos los criterios.

En conjunto, los resultados muestran que la optimización evolutiva constituye una herramienta útil para explorar alternativas de localización y analizar explícitamente los compromisos entre eficiencia, cobertura e infraestructura. Como trabajo futuro, se propone incorporar distancias y tiempos de recorrido por la red carretera, costos de instalación y operación, capacidades de almacenamiento y restricciones logísticas adicionales, con el propósito de aproximar el modelo a una aplicación real de planeación de centros de acopio.

Referencias

- [1] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, "A fast and elitist multiobjective genetic algorithm: NSGA-II," *IEEE Transactions on Evolutionary Computation*, vol. 6, no. 2, pp. 182–197, Apr. 2002, doi: 10.1109/4235.996017.
- [2] J. Blank and K. Deb, "pymoo: Multi-objective optimization in Python," *IEEE Access*, vol. 8, pp. 89497–89509, 2020, doi: 10.1109/ACCESS.2020.2990567.
- [3] M. T. Melo, S. Nickel, and F. Saldanha-da-Gama, "Facility location and supply chain management – A review," *European Journal of Operational Research*, vol. 196, no. 2, pp. 401–412, 2009, doi: 10.1016/j.ejor.2008.05.007.
- [4] H. Ge, S. J. Goetz, R. Cleary, J. Yi, and M. I. Gómez, "Facility locations in the fresh produce supply chain: An integration of optimization and empirical methods," *International Journal of Production Economics*, vol. 249, Art. no. 108534, 2022, doi: 10.1016/j.ijpe.2022.108534.
- [5] L. A. Sanabria Coronado, A. M. Peralta Lozano, and J. A. Orjuela Castro, "Modelos de localización para cadenas agroalimentarias perecedoras: una revisión al estado del arte," *Ingeniería*, 2017, doi: 10.14483/udistrital.jour.reving.2017.1.a04.
- [6] J. H. Holland, *Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence*. Ann Arbor, MI, USA: University of Michigan Press, 1975.